

**PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO GRANDE DO SUL
CENTRO DE INTELIGÊNCIA ARTIFICIAL E CIÊNCIA DE DADOS**

**Análise de Desempenho de Modelos Léxicos e Probabilísticos na
Classificação de Sentimentos**

Rafael Andrés Riveros Radomsky

Orientador: Prof. Rodrigo Goulart

**Porto Alegre
2026**

1. Problema

A classificação de sentimentos é uma subárea do Processamento de Linguagem Natural (PLN) dedicada a identificar e classificar como positiva, negativa ou neutra, strings de texto em linguagem humana. Apesar de sua ampla aplicabilidade no mercado, a tarefa é intrinsecamente complexa de se automatizar devido às divergências entre os níveis semântico e sintático da linguagem.

O principal desafio reside no fato de que computadores processam padrões matemáticos, mas não compreendem nativamente o contexto, a ironia, tom ou nuances culturais. A linguagem humana é ambígua, subjetiva e interpretativa por natureza; uma mesma palavra pode assumir conotações semânticas opostas dependendo do contexto da frase, do vocabulário de quem a profere e até mesmo da linguagem utilizada pelo falante. O objetivo deste texto é explorar essas vulnerabilidades através de algoritmos tradicionais.

2. Método

Para os experimentos, foi utilizada a NLTK (*Natural Language Toolkit*), que atua como um ecossistema de ferramentas de PLN, permitindo a escolha de diferentes abordagens para o mesmo problema. Foram testados dois modelos distintos presentes na biblioteca: o VADER e o *Naive Bayes*.

O **VADER** (*Valence Aware Dictionary and sEntiment Reasoner*) é um modelo baseado em léxico e regras empíricas, otimizado para o contexto de redes sociais. O cálculo do sentimento ocorre através da soma das valências (pesos de positividade ou negatividade) de cada palavra reconhecida na frase. Esse valor bruto é ajustado por regras heurísticas — que consideram intensificadores como letras maiúsculas, pontuação exagerada e *emojis* — e, por fim, submetido a uma função de normalização. O resultado é o escore *compound*, uma métrica contínua que varia de -1 (extremamente negativo) a +1 (extremamente positivo).

Por outro lado, o **Naive Bayes** é um classificador probabilístico clássico. Ele não possui conhecimento prévio das regras do idioma ou dicionários de valência; seu funcionamento baseia-se no Teorema de Bayes, calculando a probabilidade condicional de um texto pertencer a uma classe subjetiva ou objetiva a partir da frequência das características (palavras) aprendidas em um conjunto de dados de treinamento.

Os experimentos não foram desenhados para medir a acurácia geral dos modelos em um cenário ideal, mas sim como testes de estresse. O foco foi submeter os algoritmos a casos extremos e ambíguos para provocar falhas, evidenciando as limitações mencionadas na formulação do problema.

3. Resultados e Conclusões

Os testes mostram limitações expressivas em ambas as abordagens quando retiradas de suas zonas de conforto. O VADER demonstrou uma falha sistemática na detecção de sarcasmo, errando a classificação em 4 das 5 frases testadas, pois atribuiu peso positivo a palavras isoladas, ignorando a ironia do contexto geral. Além disso, ao ser alimentado com dados em português sem tradução prévia, o modelo retornou escore neutro (*compound* = 0.0) em todos os casos, evidenciando dependência integral de seu léxico, construído exclusivamente em inglês.

O classificador *Naive Bayes*, treinado sobre o corpus *Subjectivity* (Pang & Lee, 2004), atingiu acurácia de 80% no conjunto de testes. No entanto, o *recall* para a classe subjetiva foi de 65%, demonstrando dificuldade em separar opiniões de fatos. Em frases de sentimento misto, ambos os modelos apresentaram instabilidade: o VADER classificou "*Great product, horrible customer support*" como positivo (*compound* = +0.511), ignorando o adendo negativo explícito.

A literatura padrão frequentemente sugere a adoção de arquiteturas avançadas, como *Transformers* (ex: BERT), para mitigar problemas de contexto. Contudo, sob uma ótica de engenharia de dados, conclui-se que o gargalo central não reside apenas na escolha arquitetural do modelo, mas na infraestrutura, na representatividade dos *datasets* e nos processos de curadoria e ingestão dessas informações. A linguagem humana não é um bloco monolítico; trata-se de um fenômeno sociolinguístico extremamente dinâmico.

Portanto, propõe-se que a evolução da classificação de sentimentos exige a construção de *pipelines* robustos para o processamento de dados desestruturados (KLEPPMANN, 2017), enriquecidos com metadados de variação linguística. É necessário estratificar o treinamento por variáveis como regionalismo, estrato socioeconômico e ambiente cultural. Uma mesma palavra ou expressão pode carregar polaridades diametralmente opostas dependendo da sua origem — o contexto de uma gíria no Uruguai difere drasticamente de seu uso na Argentina, no Paraguai ou no Chile. A solução definitiva passa pela criação de modelos capazes de realizar uma análise de espectro multidirecional, compreendendo o sentimento não apenas pela sintaxe, mas pela malha cultural e demográfica de quem o emite.

4. Referências

- BIRD, S.; KLEIN, E.; LOPER, E. **Natural Language Processing with Python**. O'Reilly Media, 2009. Disponível em: <https://www.nltk.org>. Acesso em: 17 ago. 2026.
- HOVY, D. Sociodemographic Factors in Natural Language Processing. **Computational Linguistics**, v. 44, n. 4, p. 809-820, 2018.

- HUTTO, C. J.; GILBERT, E. VADER: A Parsimonious Rule-Based Model for Sentiment Analysis of Social Media Text. In: **Proceedings of the Eighth International AAI Conference on Weblogs and Social Media (ICWSM)**, 2014.
- KLEPPMANN, M. **Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems**. O'Reilly Media, 2017.
- PANG, B.; LEE, L. A Sentimental Education: Sentiment Analysis Using Subjectivity Summarization Based on Minimum Cuts. In: **Proceedings of the 42nd Annual Meeting of the Association for Computational Linguistics (ACL)**, 2004.